Unicode mixed-script corpus

This document exercises multilingual text rendering across scripts.

Japanese — 日本語テスト

これは日本語のテストです。漢字、ひらがな、カタカナを含みます。句読点、そして「かぎ括弧」も。

Chinese — 中文测试

这是一段简体中文测试文字。包含标点符号，以及数字一二三。

Korean — 한국어

한국어 테스트 문장입니다. 음절 블록과 자모를 포함합니다.

Arabic — اختبار عربي

هذا نص تجريبي باللغة العربية. يحتوي على أرقام عربية ٠١٢٣ وحروف متصلة.

Hebrew — בדיקה

זהו טקסט בדיקה בעברית. כולל ניקוד: שָׁלוֹם.

Devanagari — परीक्षण

यह देवनागरी में एक परीक्षण वाक्य है। संयुक्ताक्षर: क्ष त्र ज्ञ।

Thai — ทดสอบ

นี่คือข้อความทดสอบภาษาไทยที่ไม่มีการเว้นวรรคระหว่างคำและมีวรรณยุกต์ซ้อนกัน

Cyrillic — Тест

Это тестовый текст на русском языке. Включает букву Ё и знаки препинания.

Greek — Δοκιμή

Αυτό είναι ένα δοκιμαστικό κείμενο στα ελληνικά.

Accented Latin

café Zürich René naïve coöp Ærø façade jalapeño

Emoji

Thumbs up 👍🏽 and a family 👨‍👩‍👧‍👦 plus a heart ❤️.

Mixed direction

Total: 123 ريال

End of corpus.